Reconnaissance de signes ASL en temps réel

Modèle entraîné sur WLASL100 (100 mots) | Rapport technique | 12 octobre 2026

1. Résumé

Ce projet reconnaît **100 mots de la langue des signes américaine (ASL)**, un mot à la fois, à partir d'une webcam. Un détecteur (MediaPipe) repère le corps et les mains, un petit réseau de neurones (GRU) identifie le mot, et chaque mot reconnu peut être envoyé à une API au format JSON. L'entraînement se fait sur Google Colab, l'utilisation en direct sur le PC.

Indicateur	Valeur
Précision en validation (top-1)	**72,7 %** (120 / 165 vidéos)
Précision en test (top-1)	**75,0 %** (75 / 100 vidéos)
Validation + test réunis (top-1)	**environ 73,6 %** (195 / 265 vidéos)
Le bon mot est dans les 5 premiers choix	92,7 % (validation) et 90,0 % (test)
Précision avec le seuil de confiance 0,5	**89,3 %** sur les signes acceptés (63,4 % des signes)
Données d'entraînement	748 vidéos train (environ 7 par mot)

À retenir. Ces chiffres sont mesurés sur des vidéos du dataset WLASL que le modèle n'a jamais vues pendant l'entraînement. Ils ne garantissent pas la même précision devant ta webcam (éclairage, angle, façon de signer différents). Cette précision en conditions réelles reste à mesurer.

2. Les données

Le sous-ensemble utilisé est **nslt_100.json** : les 100 mots qui ont le plus de vidéos dans WLASL. Beaucoup de vidéos de WLASL ont disparu d'internet depuis la création du dataset, ce qui réduit fortement le nombre d'exemples.

	Train	Validation	Test	Total
Vidéos prévues (nslt_100.json)	1442	338	258	2038
Vidéos réellement présentes	748	165	100	**1013**

Le contrôle croisé avec *missing.txt* confirme que les 1025 vidéos absentes sont bien listées comme manquantes : ce n'est pas un problème de nommage. Le nombre d'exemples d'entraînement par mot va de 4 à 12 (médiane 7). C'est peu, et c'est la principale limite de précision du projet.

3. Résultats détaillés

3.1 Entraînement de contrôle (section 5 du notebook)

Trois modèles sont entraînés sur les seules vidéos de train, puis leurs prédictions sont moyennées (ensemble). Validation et test n'ont jamais servi à l'entraînement.

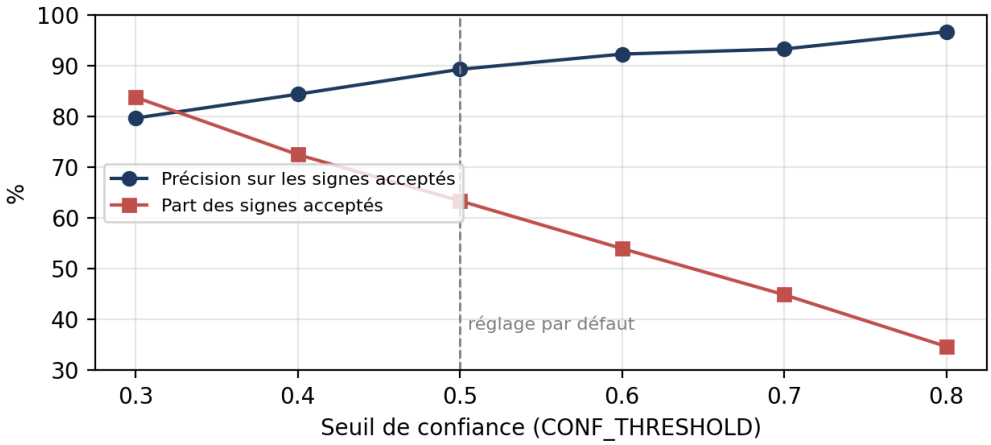
Modèle	Précision validation à la fin (époque 120)
Modèle 1 (seed 0)	67,9 %
Modèle 2 (seed 1)	74,5 %
Modèle 3 (seed 2)	70,3 %
Ensemble des 3 modèles	**72,7 % en validation, 75,0 % en test**

Les trois modèles donnent des résultats proches, donc l'entraînement est stable, et l'ensemble fait mieux que chaque modèle seul. Le test ne compte que 100 vidéos (environ une par mot) : un écart de 5 à 8 points entre deux entraînements est statistiquement normal. Le chiffre le plus fiable est celui de validation + test réunis (environ 73,6 %).

3.2 Seuil de confiance

Le script n'affiche un mot que si le modèle est assez sûr de lui. Un seuil plus élevé donne moins de fautes mais ignore davantage de signes.

Seuil	Signes acceptés	Corrects parmi les acceptés
0,3	83,8 %	79,7 %
0,4	72,5 %	84,4 %
0,5 (défaut)	**63,4 %**	**89,3 %**
0,6	54,0 %	92,3 %
0,7	44,9 %	93,3 %
0,8	34,7 %	96,7 %



Au seuil par défaut (0,5), le script ignore environ 4 signes sur 10, mais environ 9 mots affichés sur 10 sont justes. Pour moins de fautes, passer `CONF_THRESHOLD` à 0,6 (92 % de précision, 54 % des signes acceptés).

3.3 Erreurs par mot

Sur validation et test (265 vidéos), les erreurs se répartissent sur 48 mots différents. Les plus fréquents sont pizza (4), before (3), cool (3), puis shirt, no, kiss, last, go, graduate, fine, right et computer (2 chacun). Chaque mot n'ayant que 2 à 3 vidéos dans ces deux ensembles, ces écarts sont trop faibles pour conclure qu'un mot précis est plus difficile qu'un autre : il n'y a pas de groupe de mots que le modèle ne reconnaît pas du tout.

4. Ce que fait le script d'entraînement (notebook Colab)

Le notebook *ASL_Training_WLASL100.ipynb* produit le modèle *asl_model.pt* en cinq étapes.

4.1 Extraction des points clés

Pour chaque vidéo présente, MediaPipe analyse toutes les images : **PoseLandmarker** (corps) et **HandLandmarker** (jusqu'à 2 mains). Les résultats sont enregistrés dans un fichier .npy par vidéo (dossier *features_100*). L'étape est longue (20 à 40 minutes) mais se reprend automatiquement si Colab se déconnecte.

4.2 Les informations utilisées pour chaque image (282 valeurs)

Bloc	Contenu	Valeurs
Corps	7 points : nez, épaules, coudes, poignets (x, y), centrés sur le milieu des épaules et divisés par la largeur des épaules	14
Mains, position	21 points par main, mêmes coordonnées que le corps (ce que fait la main dans l'espace)	84
Mains, forme	21 points par main relatifs au poignet, divisés par la taille de la main (la forme des doigts)	84
Présence	1 si la main gauche / droite est détectée, sinon 0	2
Vitesse	Variation des 98 premières valeurs d'une image à la suivante (le mouvement)	98
Total		**282**

Chaque main est attribuée à la gauche ou à la droite selon le poignet du corps le plus proche. Le visage n'est pas utilisé. La normalisation rend le résultat indépendant de la distance à la caméra et de la résolution.

4.3 Construction d'un exemple

Pour chaque vidéo, on garde uniquement le segment du signe (images de début et de fin données par *nslt_100.json*), puis on le ramène à **32 images**, quelle que soit sa durée. L'entraînement et l'utilisation en direct appliquent exactement le même traitement (fichier *asl_common.py*).

4.4 Augmentation de données (entraînement uniquement)

- Début et fin du segment décalés aléatoirement de +/- 8 images.
- Effet miroir (mains gauche et droite échangées), avec 30 % de probabilité.
- Rotation de +/- 10 degrés, échelle de 90 à 110 %, décalage de +/- 0,1 largeur d'épaules, léger bruit.
- Chaque main est supprimée au hasard sur 5 % des images, pour imiter les ratés de détection.

4.5 Le modèle (SignNet)

- Normalisation des 282 valeurs (moyenne et écart-type calculés sur les données d'entraînement).
- Couche linéaire 282 vers 128, puis convolution temporelle avec connexion résiduelle.
- GRU bidirectionnel à 2 couches de 128 unités, qui lit les 32 images dans les deux sens.
- Résumé du temps (moyenne + maximum), dropout 0,3, puis couche finale de 100 sorties (un score par mot).

4.6 Réglages d'entraînement

Paramètre	Valeur
Optimiseur / taux d'apprentissage	AdamW, 0,002 (planning OneCycle), weight decay 0,02
Perte	Entropie croisée avec label smoothing 0,1
Époques / taille de lot	120 / 32 (coupure de gradient à 1,0)
Contrôle (section 5)	3 modèles entraînés sur train seul, évalués sur val et test
Final (section 6)	5 modèles entraînés sur train + val + test, prédictions moyennées
Fichier produit	asl_model.pt (les 5 modèles + la liste des 100 mots)

Le modèle final est réentraîné sur toutes les vidéos car chaque exemple compte. Sa précision réelle est donc estimée par l'entraînement de contrôle (section 3), pas par le modèle final : le score élevé affiché à la fin de la section 6 porte sur des vidéos déjà vues et n'a pas de valeur de mesure.

5. Ce que fait le script du PC (asl_live.py)

Le script lit la webcam image par image et reproduit la même chaîne de traitement que l'entraînement, avec les mêmes fonctions de *asl_common.py*. Voici ce qui se passe, dans l'ordre.

Étape	Ce qui se passe
1. Capture	Image de la webcam (640 x 480). L'image traitée n'est **pas retournée**, comme pendant l'entraînement ; seul l'affichage est en miroir.
2. Détection	MediaPipe détecte le corps et les mains, qui sont transformés en 184 valeurs (puis 282 avec la vitesse), exactement comme à l'entraînement.
3. Mains actives ?	Une main détectée dont le poignet est au-dessus d'environ une largeur d'épaules sous les épaules (ACTIVE_Y = 1,0) compte comme « en train de signer ».
4. Début du signe	3 images consécutives actives (START_FRAMES) : l'enregistrement démarre, avec 8 images gardées avant le début (PRE_ROLL).
5. Fin du signe	10 images consécutives mains basses ou non détectées (END_FRAMES). Les segments de moins de 10 images de mouvement (MIN_LEN) sont ignorés ; ceux de plus de 150 images (MAX_LEN) sont coupés.
6. Prédiction	Le segment est ramené à 32 images. Il est testé en 4 variantes (entier, sans les 2 premières images, sans les 2 dernières, sans les deux), chacune passée dans les 5 modèles ; toutes les probabilités sont moyennées.
7. Décision	Le mot est accepté si sa confiance est au moins de 0,50 (CONF_THRESHOLD) **et** dépasse le deuxième choix d'au moins 0,15 (MARGIN_THRESHOLD). Sinon, le signe est rejeté plutôt que d'afficher un mauvais mot.
8. Affichage et envoi	Le mot et la phrase en cours s'affichent à l'écran. Si API_URL est renseignée, un envoi JSON (POST) part en arrière-plan, sans bloquer la caméra.

5.1 Format envoyé à l'API

```
{"word": "help", "confidence": 0.91, "sentence": "need help", "timestamp": 1760000000.0}
```

Les noms de champs se modifient dans la fonction `build_payload` si l'API de ton ami attend un autre format. Une erreur d'envoi s'affiche dans le terminal sans arrêter le programme.

5.2 Réglages principaux à connaître

Réglage	Effet	Défaut
CONF_THRESHOLD	Plus haut = moins de fautes, plus de signes ignorés	0,50
MARGIN_THRESHOLD	Écart minimal entre le 1er et le 2e choix	0,15
ACTIVE_Y	Hauteur à partir de laquelle une main compte comme active	1,0
END_FRAMES	Durée mains basses pour terminer un signe	10 images
API_URL	Adresse de l'API (vide = pas d'envoi)	vide
CAMERA_INDEX	Numéro de la webcam (essayer 1 ou 2 sinon)	0

Touches : **q** quitte, **c** efface la phrase, **espace** envoie la phrase à l'API.

6. Fichiers du projet

Fichier	Rôle	Où il sert
ASL_Training_WLASL100.ipynb	Extraction des points clés, entraînement, export du modèle	Colab
asl_common.py	Prétraitement et modèle, partagés (à ne pas modifier d'un seul côté)	Colab et PC
asl_model.pt	Le modèle entraîné (5 réseaux + liste des mots)	PC
asl_live.py	Reconnaissance en direct avec la webcam et envoi à l'API	PC
classes.txt, rapport_precision.json	Liste des 100 mots et chiffres de précision	Archive

7. Limites et pistes d'amélioration

Limites

- **Mots isolés.** Le modèle reconnaît un signe à la fois. La suite de mots affichée n'est pas une phrase grammaticale en ASL ; la reconnaissance de phrases continues demande d'autres datasets.
- **Vocabulaire fixe de 100 mots**, avec peu de pronoms et de verbes de liaison.
- **Peu de données** : environ 7 vidéos d'entraînement par mot, car la moitié du dataset n'est plus disponible.
- **Écart avec la webcam.** Les 73 % sont mesurés sur WLASL, pas sur ta caméra. La précision réelle devant la webcam est probablement inférieure et doit être mesurée.
- **Test peu précis** : 100 vidéos seulement, donc les chiffres bougent de plusieurs points d'un entraînement à l'autre.

Pistes, par ordre d'intérêt

- **Enregistrer tes propres exemples** (quelques répétitions par mot devant ta webcam) et les ajouter à l'entraînement : c'est l'amélioration la plus efficace pour la précision réelle.
- Ajuster CONF_THRESHOLD et ACTIVE_Y selon les premiers essais.
- Choisir un vocabulaire sur mesure parmi les 2000 mots de WLASL (avec au moins 8 à 10 vidéos par mot).
- Ajouter une étape qui transforme la suite de mots en phrase anglaise correcte, par exemple avec un modèle de langage.

Crédits. Dataset WLASL (Li et al., WACV 2020), à utiliser selon sa licence. Détection du corps et des mains : MediaPipe (Google). Réseau de neurones : PyTorch.